

A night-time photograph of the Seattle skyline, featuring the Space Needle and various illuminated skyscrapers against a dark, cloudy sky. A large purple rectangular banner is overlaid across the middle of the image, containing the title text in white.

# Soutenance du projet 3

Anticipez les besoins en consommation d'énergie  
des bâtiments pour la ville de Seattle

# Etape 1

## Rappel de la problématique

# Rappel de la problématique

## Seattle vise la neutralité carbone d'ici 2050

- Les bâtiments non résidentiels consomment une part importante de l'énergie de la ville.
- En 2016, des relevés précis ont été effectués, mais ils sont coûteux.
- Objectif : **estimer les émissions de CO2 et la consommation énergétique** de ces bâtiments sans effectuer de nouvelles mesures sur site.




# Rappel de la problématique

## Problème à résoudre

- Comment **prédire efficacement les émissions de CO2 et la consommation d'énergie** des bâtiments non résidentiels ?
- Peut-on utiliser les caractéristiques structurelles des bâtiments pour estimer ces valeurs ?
- **L'ENERGY STAR Score**, actuellement coûteux à calculer, est-il un bon indicateur pour nos prédictions ?



# Approches et méthodologies



# Etape 2

## Présentation du jeu de données

# Présentation du jeu de données

01

Comprendre le jeu de données et  
Identifier les variables pertinentes pour la  
prédiction de la consommation d'  
énergie

## Suppression des lignes

J'ai retiré du jeu de données, les bâtiments résidentiels  
J'ai gardé uniquement les lignes ayant des données complètes  
grâce à la colonne 'ComplianceStatus = compliant'

Lignes : 3 376

Colonnes : 46



Lignes : 1 548

Colonnes : 46

# Présentation du jeu de données

02

J'ai supprimé les colonnes jugées inutiles ou redondantes pour la prédiction, tout en conservant celles pouvant être exploitées lors du Feature Engineering.

J'ai vérifié l'**absence de doublons** dans le jeu de données.

J'ai supprimé les colonnes contenant uniquement **cinq valeurs manquantes**.

J'ai également **corrigé le type des colonnes** inappropriées en les convertissant au bon format.

Lignes : 1 548

Colonnes : 46



Lignes : 1 543

Colonnes : 23



# Présentation du jeu de données

03

J'ai identifié et remplacer les valeurs manquantes et aberrantes.

Exemple de valeurs aberrantes :

- Une propriété qui consomme beaucoup d'énergie alors qu'il a 0 niveau, 0 building
- Une propriété dont la superficie total est inférieur à la superficie de la plus grande propriété
- Des propriétés qui ne consomment rien alors qu'ils ont des bâtiments et un useType.

Avec le type de la propriété j'ai remplis les 2 colonnes à prédire

# Présentation du jeu de données

## Analyse univariée et bivariée

04

Cette analyse m'a révélé une distribution asymétrique des colonnes à prédire.

Elle m'a également permis d'identifier les corrélations entre variables et de commencer le Feature Engineering.

Lignes : 1 543

Colonnes : 23



Lignes : 1 543

Colonnes : 17

# Etape 3

## Présentation du feature engineering

# Présentation du feature engineering

## Itération

### 01

Pour cette itération, j'ai effectué les transformations suivantes :

- Création de tranches pour l'année de construction (de 1900 à 1925 avec un pas de 25 ans).
- Regroupement du nombre de niveaux par tranches de 5.
- Calcul des proportions de superficie entre le parking et le bâtiment.
- Détermination des proportions des différentes sources d'énergie.

Les autres itérations s'appuient sur cette première version, avec des ajustements comme l'ajout de nouvelles colonnes ou la modification des intervalles.

## Encoding

Label encoding et One Hot encoding

# Présentation du feature engineering

Itération

01

Label encoding :

- NumberofFloorsRange

One hot encoding :

- YearBuiltRange
- Neighborhood
- PrimaryPropertyType

Suppressions de OSEBuildingID  
et ENERGYSTARScore

Lignes : 1 543

Colonnes : 17

Lignes : 1 543

Colonnes : 15

Lignes : 1 543


Colonnes : 52

# Présentation du feature engineering

Itération

02

Regroupement des catégories  
"PrimaryPropertyType"  
en des groupes plus  
restreint



# Présentation du feature engineering

Itération

03

Elle reprend les mêmes transformations que l'itération 2, à la différence que le pas pour l'année de construction est de 10 au lieu de 5.

Meilleure  
itération : 01

Itération

04


Pas de 5.

Deuxième regroupement des catégories "PrimaryPropertyType" en groupes plus restreints.

# Présentation du feature engineering

Itération

04





# Présentation du feature engineering

Itération

05

itération 01 + Label Encoding

Meilleure  
itération : 01

Itération

06


- Avec SHARP Je revois les colonnes que je veux garder
- Je remplace les années par 2 colonnes avant 1950 et après 1950

Meilleure  
itération : 06

# Présentation du feature engineering

## Vérification de l'impact de la transformation logarithmique

J'ai remarqué qu'en appliquant la transformation logarithmique et la standardisation des données X j'obtenais de meilleurs résultats.




# Etape 4

## Explication de l'approche de modélisation

SiteEnergyUseWN(kBtu)

# Explication de l'approche de la modélisation

## Modèles Simples



## Pourquoi entraîner sur des modèles simples?

- Ils aident à repérer rapidement les erreurs ou incohérences dans les données.
- Ils fournissent une ligne de base pour comparer les modèles plus complexes.


# Explication de l'approche de la modélisation

## Modèles complexes

DecisionTree

04


Score :  
0.4426



Gradient  
Boosting

05

Score :  
0.7045



# Explication de l'approche de la modélisation

## Une fois le meilleur modèle trouvé

- J'ai utilisé SHARP afin de comprendre les colonnes qui impactent fortement le modèle



# Explication de l'approche de la modélisation

## Evaluation de l'importance de Energy Star Score

Lignes : 1 543

Lignes : 994

Gradient Boosting

Score test : 0.7863  
Score Val : 0.8056

Modèle avec EnergyStarScore

Score test : 0.7863  
Score Val : 0.8056

Modèle sans EnergyStarScore

Score test : 0.7385  
Score Val : 0.7334

# Etape 4

## Explication de l'approche de modélisation


GHGEmissionsIntensity



# Explication de l'approche de la modélisation

## Meilleur modèle


Gradient  
Boosting




Score : 0.6178

# Explication de l'approche de la modélisation

C02




Energy




# Explication de l'approche de la modélisation

C02



Energy



# Explication de l'approche de la modélisation

## Evaluation de l'importance de Energy Star Score

**Gradient Boosting**

**Score test : 0.3875**  
**Score Val : 0.6178**

**Modèle avec EnergyStarScore**

**Score test : 0.6528**  
**Score Val : 0.7280**

**Modèle sans EnergyStarScore**

**Score test : 0.6257**  
**Score Val : 0.6448**